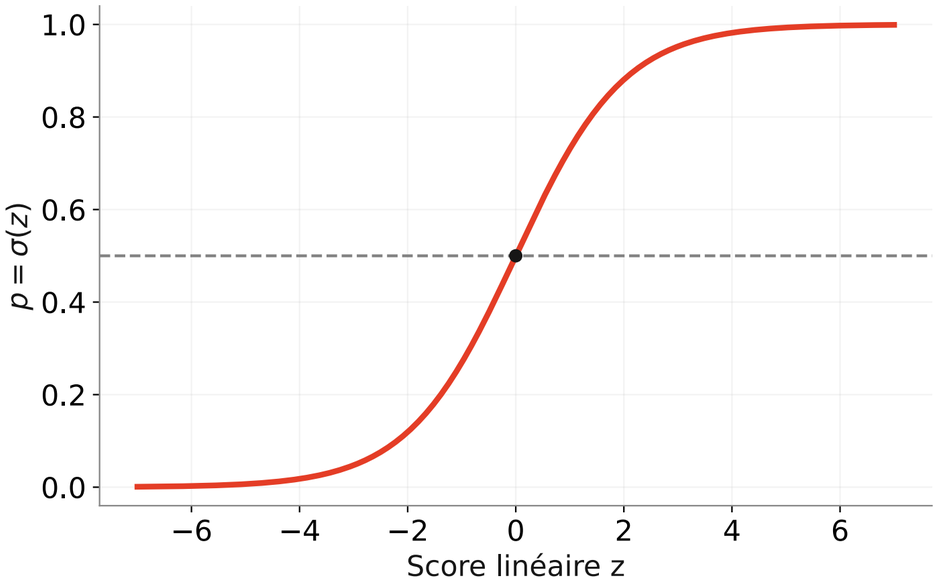
# De la régression à la classification.

Comment les modèles apprennent, estiment des probabilités et prennent des décisions.




**Modèle → perte → gradient → évaluation → décision.**

# Trois repères, un même problème d’apprentissage

Ajuster une droite, estimer une probabilité de classe et entraîner un réseau demandent d’apprendre des paramètres à partir d’observations.

Question centrale : **quels paramètres expliquent les observations et prédisent bien de nouveaux cas ?**

01 **1805 · Legendre**
Moindres carrés : combiner des observations bruitées en minimisant les erreurs au carré.

02 **1958 · Cox**
Régression binaire : relier la probabilité de 1 aux variables explicatives.

03 **1986 · Rumelhart, Hinton et Williams**
Rétropropagation : organiser la règle de chaîne dans un réseau.

**Modèle → fonction objectif → optimisation → prédiction.**

# Définir la prédiction avant de choisir le modèle

Chaque exemple contient une entrée $x_i$ et une cible connue. L'indice $i$ désigne une observation ; $n$ est la taille du jeu d'entraînement.

Fil conducteur : distance $x$ (km) et durée de marche $y$ (min).

Les paramètres $w, b$ sont appris. Une caractéristique doit être disponible au moment de prédire.

| Tâche | Cible | Sortie |
|---|---|---|
| **Régression** | $y \in \mathbb{R}$ | Durée |
| **Classification** | $c \in \{0, 1\}$ | Plus de 30 min ? |

$$\hat{y} = wx + b$$

$$p = P(c = 1 \mid x)$$

**Une cible numérique et une classe demandent des interprétations différentes.**

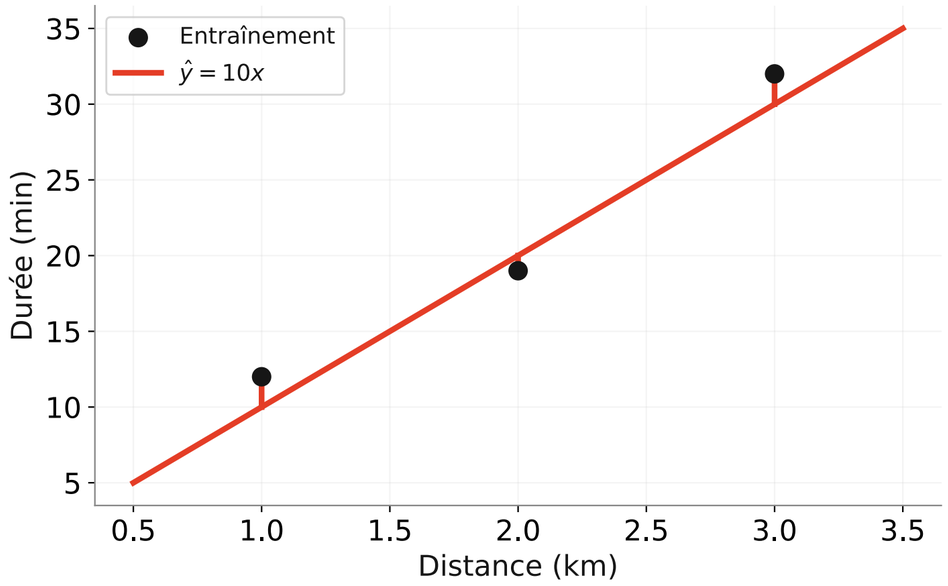
# Régression linéaire : préciser le « meilleur ajustement »

Le modèle prédit $\hat{y}_i = wx_i + b$. Le résidu signé est la prédiction moins l'observation : $r_i = \hat{y}_i - y_i$.

$$J(w, b) = \frac{1}{2n} \sum_{i=1}^{n} r_i^2$$

Le carré évite la compensation des erreurs et donne davantage de poids aux grands écarts.

$J = \mathrm{MSE}/2$. Le facteur $1/2$ simplifie les dérivées sans changer le minimum.




Pour $w = 10, b = 0$, les résidus sont $(-2, 1, -2)$ min ; $J = (4 + 1 + 4)/6 = 1.5$ min².

**La perte transforme « ajuster les données » en un objectif d'optimisation explicite.**

# Le gradient suit le calcul

Pour une observation, $\ell_i = r_i^2/2$. Une dérivée mesure la variation de la perte lors d'une petite variation d'un paramètre.

$$\frac{\partial \ell_i}{\partial w} = \frac{\partial \ell_i}{\partial r_i}\frac{\partial r_i}{\partial w} = r_i x_i$$

$$\frac{\partial \ell_i}{\partial b} = r_i \cdot 1$$

La dérivée d'une somme est la somme des dérivées. On moyenne les contributions de toutes les observations.

**01** **Calcul direct**

$w, b \longrightarrow \hat{y}_i \longrightarrow r_i \longrightarrow \ell_i$

**02** **Dérivation**

Chemin de $w$ : multiplier $r_i$ par $x_i$. Chemin de $b$ : multiplier par 1.

$$g_w = \frac{1}{n}\sum_i r_i x_i$$

$$g_b = \frac{1}{n}\sum_i r_i$$

**La règle de chaîne relie les dérivées locales à l'effet d'un paramètre sur la perte.**

# Une mise à jour calculée à la main

Partir de $w = 10, b = 0$. Calculer les deux gradients à partir des mêmes anciens paramètres.

| $x_i$ | $y_i$ | $r_i$ | $r_i x_i$ |
|---|---|---|---|
| **1** | 12 | −2 | −2 |
| **2** | 19 | 1 | 2 |
| **3** | 32 | −2 | −6 |

$$g_w = -6/3 = -2, \qquad g_b = -3/3 = -1$$

> $$w^+ = w - \eta g_w, \quad b^+ = b - \eta g_b$$

Avec un pas d'apprentissage $\eta = 0.1$ :

$$w^+ = 10.2, \qquad b^+ = 0.1$$

Les nouveaux résidus sont $(-1.7, 1.5, -1.3)$.

$$J^+ = 6.83/6 \approx 1.1383 < 1.5$$

**Soustraire le gradient ; mettre à jour tous les paramètres simultanément.**

# Une solution exacte vérifie l’itération

Au minimum différentiable, les deux dérivées partielles sont nulles. Pour ces données :

$$14w + 6b = 146$$

$$6w + 3b = 63$$

La perte a une forme de bol (convexe), sans faux minimum local. Des distances distinctes rendent ce point stationnaire unique et global.

$$w_* = 10, \qquad b_* = 1$$

$$\hat{y} = 10x + 1, \qquad J_* = 1$$

**01** **Interprétation**

Pente : 10 min/km. Ordonnée à l’origine : 1 min, un décalage ajusté.

**02** **Géométrie**

À l’optimum, $\sum_i r_i = 0$ et $\sum_i r_i x_i = 0$. Les résidus s’équilibrent selon les directions ajustées.

**Les moindres carrés se résolvent directement ; l’optimisation itérative s’étend à d’autres modèles.**

# Le pas contrôle la dynamique d'apprentissage

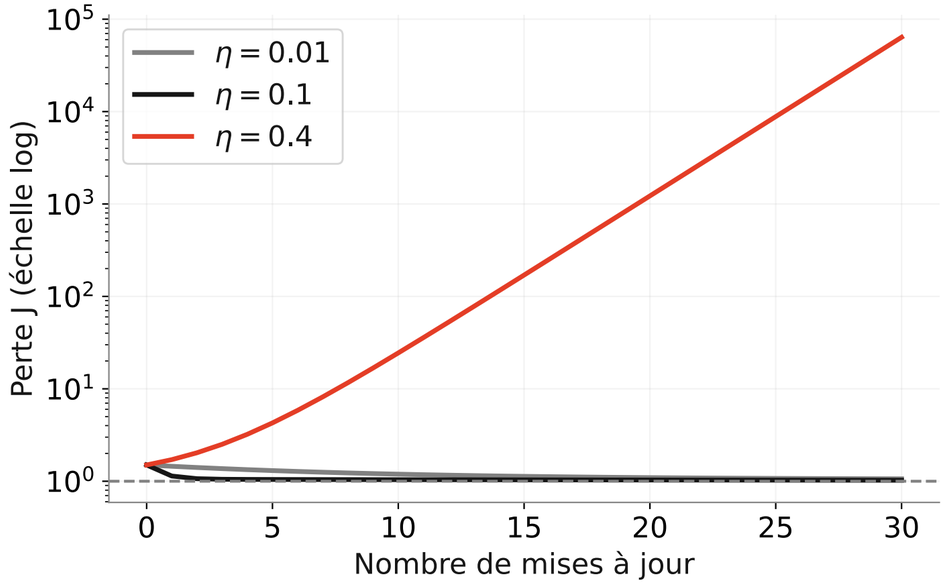
Le gradient indique une direction locale de descente. Le pas $\eta$ fixe la distance parcourue.

**01 Trop petit**
La progression peut être lente.

**02 Adapté**
La perte diminue vers le minimum.

**03 Trop grand**
La mise à jour peut dépasser le minimum et diverger.

Les unités influencent les gradients et les pas utilisables.




Mêmes observations et même départ ; seul le pas change. L'axe vertical est logarithmique.

**Un gradient correct ne garantit pas que tout pas de taille finie réduise la perte.**

# Entraîner : une boucle ; prédire : un calcul

**01 Initialiser**
Choisir paramètres, perte, pas et critère d'arrêt.

**02 Prédire et mesurer**
Calculer les prédictions et la perte moyenne.

**03 Dériver et mettre à jour**
Calculer tous les gradients, puis modifier les paramètres.

**04 Répéter**
Arrêter selon la règle prévue ; conserver les paramètres.

$$\theta^{(t+1)} = \theta^{(t)} - \eta \nabla J(\theta^{(t)})$$

Ici $\theta = (w, b)$, $t$ compte les mises à jour, et $\nabla J$ regroupe les dérivées partielles.

Lors de la prédiction, fixer les paramètres et évaluer la fonction sur une nouvelle entrée.

$$x_{\text{new}} = 2.4 \implies \hat{y} = 25 \text{ min}$$

**L'algorithme d'apprentissage produit une fonction de prédiction réutilisable.**

# Trois jeux de données, trois questions

Une faible perte d’entraînement décrit des cas déjà utilisés pour ajuster le modèle. Notre objectif concerne les cas futurs.

Séparer avant l’ajustement. L’usage peut imposer un découpage temporel ou par groupes : dates futures, nouveaux utilisateurs.

Consulter souvent le test le transforme en source de sélection.

01 **Entraînement · ajuster**
Estimer les paramètres grâce à la perte d’entraînement.

02 **Validation · choisir**
Choisir complexité, hyperparamètres et seuil de décision.

03 **Test · mesurer**
Une fois les choix figés, mesurer sur des exemples intacts.

**La généralisation se mesure sur des données qui n’ont guidé ni l’ajustement ni la sélection.**

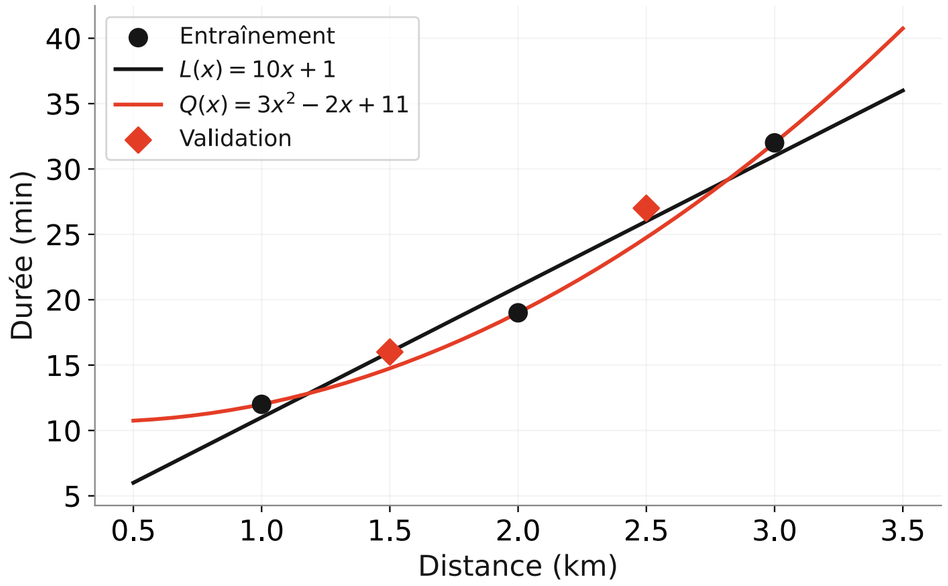
# Un ajustement parfait peut moins bien généraliser

Comparer deux candidats ajustés sur les mêmes observations, avec l'erreur quadratique moyenne (MSE).

| Modèle | MSE entraîn. | MSE validation |
|---|---|---|
| **Droite L** | 2 | 0.5 |
| **Quadratique Q** | 0 | 3.3125 |

Validation : $(1.5, 16)$ et $(2.5, 27)$. L prédit $(16, 26)$ ; Q prédit $(14.75, 24.75)$.

La validation sélectionne la droite. Un test distinct reste nécessaire.




Une flexibilité accrue peut suivre les fluctuations d'entraînement. Ces petits jeux illustrent le protocole, pas des performances fiables.

**L'optimisation juge l'ajustement ; l'évaluation juge son transfert à de nouvelles données.**

# Utiliser l’information disponible au moment de prédire

La distance est connue avant le trajet. L’heure d’arrivée révèle le résultat après le trajet : elle ne peut servir d’entrée ici.

Le prétraitement apprend aussi. Estimer moyennes et écarts-types uniquement sur l’entraînement.

Réutiliser ces valeurs en validation, en test et pour les futures entrées.

$$x' = \frac{x - \mu_{\text{train}}}{s_{\text{train}}}$$

**01** **Apprendre sur l’entraînement**
Estimer $\mu_{\text{train}}$ et $s_{\text{train}} > 0$.

**02** **Transformer tous les jeux**
Réutiliser la transformation fixée.

**03** **Respecter le protocole**
Choisir une transformation relève de la validation.

**La fuite de données laisse entrer de l’information sur la réponse dans la procédure de prédiction.**

# La classification prédit des catégories

La cible est une catégorie. Son code numérique identifie une classe ; il ne représente pas une grandeur mesurée.

**01 Binaire**
Deux issues exclusives : courriel indésirable ou légitime.

**02 Multiclasse**
Une classe parmi plusieurs : le chiffre 0, 1, ..., 9.

**03 Multi-étiquette**
Plusieurs étiquettes possibles : une photo peut montrer une personne et un vélo.

$$\text{binaire} : \quad c \in \{0, 1\}$$

$$\text{multiclasse} : \quad c \in \{1, \ldots, K\}$$

$$\text{multi-etiquette} : \quad \mathbf{c} \in \{0, 1\}^K$$

Apprendre une probabilité binaire, la transformer en décision de classe, puis évaluer les décisions.

La régression logistique est un modèle de classification malgré le mot « régression ».

**Tâche → modèle probabiliste → décision de classe → évaluation de classification.**

# Le trajet dépassera-t-il 30 minutes ?

Définir $c = 1$ si la durée mesurée dépasse 30 min ; sinon $c = 0$ .

$$p(x) = P(c = 1 \mid x)$$

La distance reste l’entrée. La sortie estime maintenant la probabilité d’un événement.

Des facteurs non observés, comme la vitesse, rendent plusieurs résultats possibles pour une même distance.

| Distance x | Durée y | Classe c |
|---|---|---|
| **1** | 12 | 0 |
| **2** | 19 | 0 |
| **3** | 32 | 1 |
| **4** | 29 | 0 |
| **5** | 48 | 1 |
| **6** | 57 | 1 |

**Une probabilité prédite et une décision binaire sont deux sorties distinctes.**

# Donner une interprétation probabiliste au score

Un score brut $z = wx + b$ peut prendre toute valeur réelle. Une probabilité doit être comprise entre 0 et 1.

Il faut une transformation lisse du score en probabilité, pour pouvoir dériver l'effet des paramètres.

Tronquer la droite à 0 et 1 crée des zones plates et ne définit pas un objectif probabiliste d'apprentissage.

**01 Caractéristique**

$x \in \mathbb{R}$

**02 Score linéaire**

$z = wx + b \in \mathbb{R}$

**03 Probabilité**

$p = \sigma(z) \in (0, 1)$

**04 Décision ensuite**

Comparer $p$ à un seuil $\tau$.

**Le score combine les caractéristiques ; le lien probabiliste lui donne une échelle interprétable.**

# Déduire la sigmoïde d’une cote logarithmique linéaire

Pour une probabilité $p$, la cote vaut $p/(1-p)$. À $p=0.75$, elle vaut $3:1$.

La régression logistique suppose que le logarithme de la cote dépend linéairement des caractéristiques. C’est une hypothèse de modèle.

$$\log \frac{p}{1-p} = z = wx + b$$

Dans ce cours, log désigne le logarithme naturel.

$$\frac{p}{1-p} = e^z$$

$$p = e^z(1-p)$$

$$p(1+e^z) = e^z$$

$$p = \frac{e^z}{1+e^z} = \frac{1}{1+e^{-z}}$$

La dernière expression définit la sigmoïde logistique.

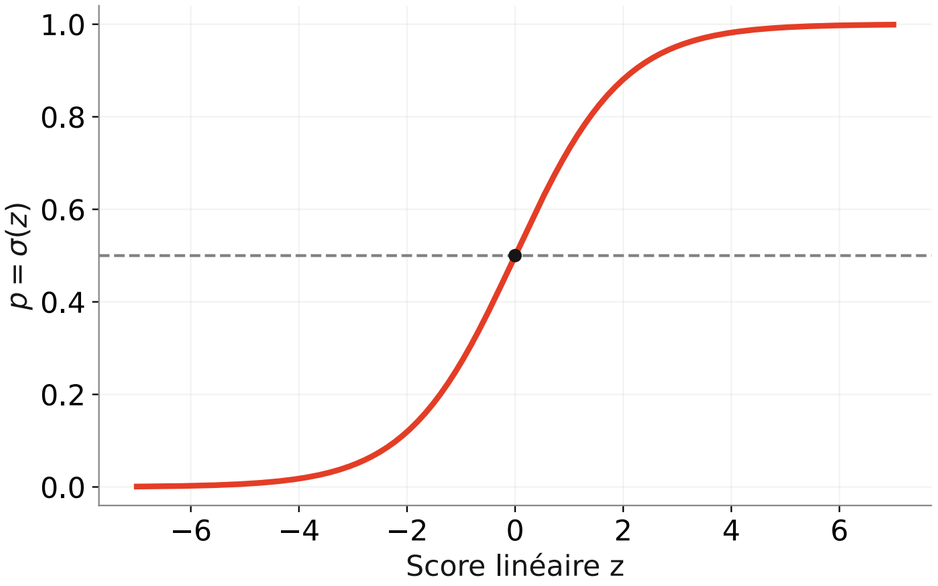
**La sigmoïde découle algébriquement de l’hypothèse d’une cote logarithmique linéaire.**

# Lire la sigmoïde comme une échelle de probabilité

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

| Score | Probabilité |
|---|---|
| $z = 0$ | $p = 0.5$ |
| $z \to +\infty$ | $p \to 1$ |
| $z \to -\infty$ | $p \to 0$ |

La courbe est continue et strictement croissante. Un score plus grand implique une probabilité estimée plus élevée de la classe 1.




Symétrie : $\sigma(-z) = 1 - \sigma(z)$. Les valeurs 0 et 1 ne sont jamais atteintes pour un score fini.

**Une probabilité proche de 0.5 exprime une incertitude du modèle.**

# Calculer une probabilité avant de décider

Pour un calcul exact, prendre les paramètres illustratifs $w = \log 3$ et $b = -3\log 3$. Ils ne proviennent pas d'un ajustement.

$$z = (x - 3)\log 3$$

À $x = 4$ km, $z = \log 3$. La cote vaut 3 et la probabilité vaut $3/4$.

| x | z | p |
|---|---|---|
| **2** | $-\log 3$ | 0.25 |
| **3** | 0 | 0.50 |
| **4** | $\log 3$ | 0.75 |

Une probabilité de 0.75 estime l'événement « durée supérieure à 30 min ». Elle ne garantit pas le résultat de ce trajet.

Il reste à définir un objectif pour apprendre les paramètres.

**La probabilité est une sortie du modèle ; sa fiabilité se vérifie sur des données.**

# Rendre les étiquettes observées vraisemblables

Le modèle de Bernoulli donne $P(c=1 \mid x)=p$ et $P(c=0 \mid x)=1-p$.

$$P(c_i \mid x_i)=p_i^{c_i}(1-p_i)^{1-c_i}$$

Vérifier les deux cas : une étiquette de 1 donne p ; une étiquette de 0 donne 1−p.

Supposer les étiquettes conditionnellement indépendantes, sachant les entrées et paramètres. La vraisemblance jointe est :

$$L(w,b)=\prod_{i=1}^{n} p_i^{c_i}(1-p_i)^{1-c_i}$$

Les observations sont fixées. La vraisemblance est une fonction des paramètres.

Le maximum de vraisemblance choisit les paramètres qui maximisent cette valeur jointe.

**La vraisemblance utilise la probabilité attribuée aux étiquettes réellement observées.**

# De la vraisemblance à l’entropie croisée binaire

Le logarithme transforme un produit en somme. Comme il est croissant, maximiser la vraisemblance ou son logarithme donne la même solution.

Le signe moins transforme le maximum en minimum. Diviser par n donne une perte moyenne.

$$J = -\frac{1}{n}\log L$$

$$\ell(p, c) = -c\log p - (1-c)\log(1-p)$$

$$J(w, b) = \frac{1}{n}\sum_{i=1}^{n}\ell(p_i, c_i)$$

| Étiquette observée | Perte |
|---|---|
| **c = 1** | $-\log p$ |
| **c = 0** | $-\log(1-p)$ |

Entropie croisée binaire (BCE), ou perte logarithmique.

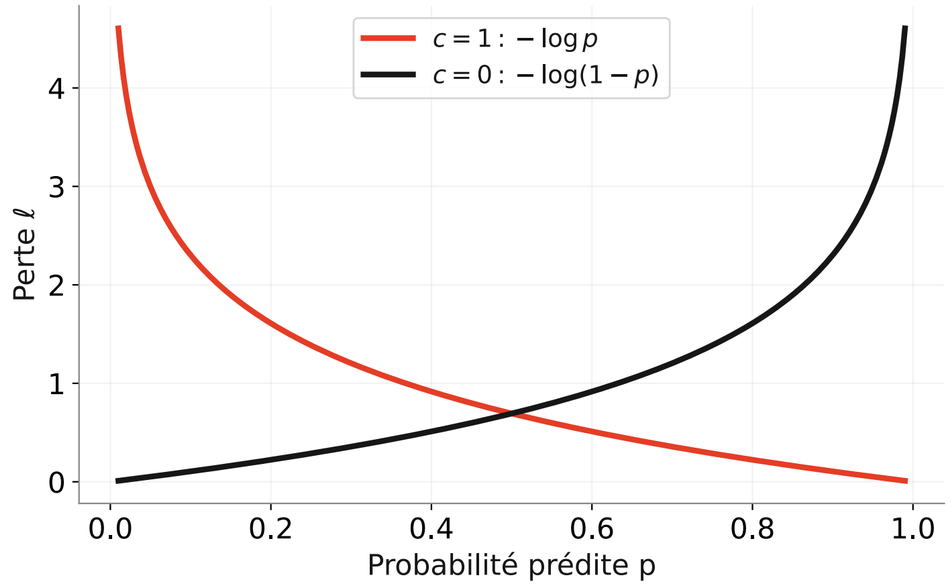
**L’entropie croisée est la log-vraisemblance négative moyenne du modèle de Bernoulli.**

# Les erreurs confiantes reçoivent une forte pénalité

Pour une étiquette vraie de 1, augmenter la probabilité réduit la perte. Le sens s'inverse pour une étiquette de 0.

| Vrai c | p prédit | Perte |
|---|---|---|
| **1** | 0.9 | 0.105 |
| **1** | 0.5 | 0.693 |
| **1** | 0.1 | 2.303 |

L'exactitude traite les erreurs de décision également. L'entropie croisée évalue aussi les probabilités.




La perte devient très grande si le modèle attribue une probabilité presque nulle au résultat observé.

**Apprendre un modèle probabiliste demande davantage que compter les bonnes étiquettes.**

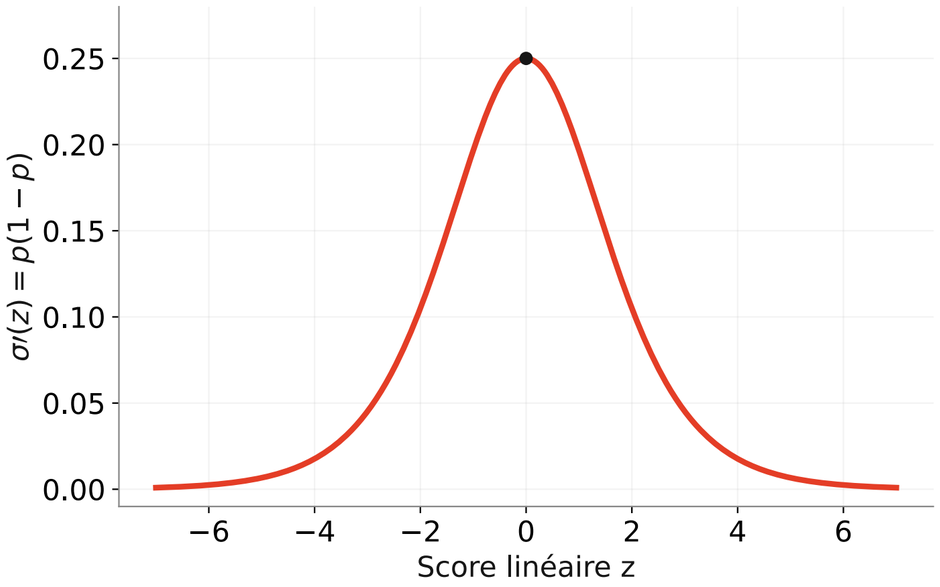
# Dériver d’abord la sigmoïde

Écrire $p = (1 + e^{-z})^{-1}$. Appliquer la dérivation d’une puissance et la règle de chaîne :

$$\frac{dp}{dz} = \frac{e^{-z}}{(1+e^{-z})^2}$$

$$1 - p = \frac{e^{-z}}{1+e^{-z}}$$

$$\frac{dp}{dz} = p(1-p)$$




Pente maximale : $1/4$ en $z = 0$. Loin de 0, la probabilité varie lentement avec le score.

**Cette dérivée locale est un facteur de la dérivée de la perte d’entraînement.**

# La règle de chaîne donne : prédiction moins étiquette

Dériver d'abord la perte par rapport à son entrée probabiliste :

$$\frac{\partial \ell}{\partial p} = -\frac{c}{p} + \frac{1-c}{1-p}$$
$$= \frac{p-c}{p(1-p)}$$

Multiplier par $dp/dz = p(1-p)$. Pour $z$ fini, $0 < p < 1$ : la simplification est valide.

$$\frac{\partial \ell}{\partial z} = \frac{p-c}{p(1-p)} p(1-p) = p - c$$

$$\frac{\partial \ell}{\partial w} = (p-c)x$$

$$\frac{\partial \ell}{\partial b} = p - c$$

Pour c = 1 et p trop petit, la dérivée selon le score est négative : augmenter le score réduit la perte.

**Sigmoïde + entropie croisée donnent un gradient particulièrement simple selon le score.**

# Moyenner les gradients, puis mettre à jour

$$p_i = \sigma(wx_i + b)$$

$$g_w = \frac{1}{n}\sum_i (p_i - c_i)x_i$$

$$g_b = \frac{1}{n}\sum_i (p_i - c_i)$$

Tous les exemples contribuent au gradient du lot. Un exemple peut tirer dans une direction différente de la moyenne.

**01 Prédire**
Calculer les scores $z_i$ et probabilités $p_i$.

**02 Comparer**
Calculer $p_i - c_i$ avec les étiquettes observées.

**03 Mettre à jour**
$w^+ = w - \eta g_w, \quad b^+ = b - \eta g_b$

**04 Répéter**
Suivre la perte et appliquer le critère d'arrêt.

**La boucle reste la même ; la prédiction et la perte changent.**

# Une mise à jour logistique sur six observations

Partir de $w = b = 0$ : toutes les probabilités valent 0.5 ; la perte moyenne vaut $\log 2 \approx 0.693147$.

| x | 1 | 2 | 3 | 4 | 5 | 6 |
|---|---|---|---|---|---|---|
| c | 0 | 0 | 1 | 0 | 1 | 1 |
| p−c | .5 | .5 | −.5 | .5 | −.5 | −.5 |

$$g_b = 0, \qquad g_w = -\frac{7}{12}$$

Avec $\eta = 0.1$, mettre à jour les deux paramètres :

$$w^+ = \frac{7}{120} \approx 0.05833, \quad b^+ = 0$$

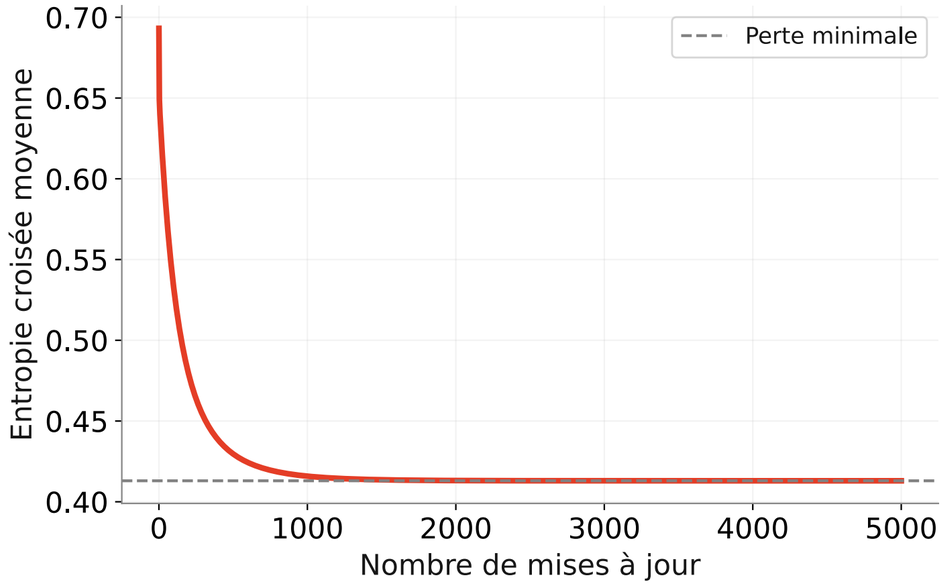
$$p^+(3) = \sigma(0.175) \approx 0.54364$$

La nouvelle BCE moyenne vaut **0.665548**, contre 0.693147 au départ.

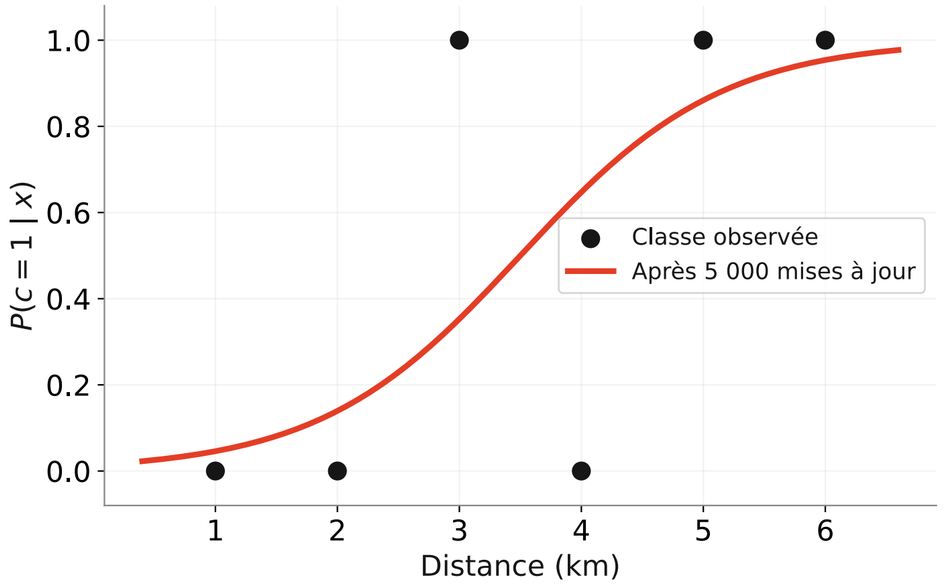
Les six probabilités dépassent 0.5. Réduire la perte n’améliore pas nécessairement l’exactitude.

**La mise à jour numérique applique directement le gradient obtenu.**

# Répéter la mise à jour pour ajuster la courbe




Descente sur le lot complet, $\eta = 0.1$, 5 000 mises à jour, départ $w = b = 0$.




Les classes en x = 3 et x = 4 contredisent une règle croissante parfaite. La courbe ajustée fait un compromis.

**Une perte d'entraînement décroissante montre l'optimisation ; l'évaluation sur de nouvelles données reste nécessaire.**

# Un seuil transforme la probabilité en décision

Choisir $0 < \tau < 1$. Prédire la classe 1 si $p \geq \tau$, sinon la classe 0. Dans ce cours, l'égalité appartient à la classe 1.

$$\hat{c} = 1[p \geq \tau]$$

L'indicatrice vaut 1 si la condition entre crochets est vraie, et 0 sinon.

La sigmoïde est croissante. Un seuil de probabilité équivaut donc à un seuil de score :

$$p \geq \tau \iff z \geq \log \frac{\tau}{1-\tau}$$

$$\tau = 0.5 \implies wx + b \geq 0$$

Avec les paramètres illustratifs de la page 18, la frontière à τ = 0.5 est x = 3 km.

**Le seuil de décision est distinct de la fonction probabiliste apprise.**

# Avec deux caractéristiques, la frontière est une droite

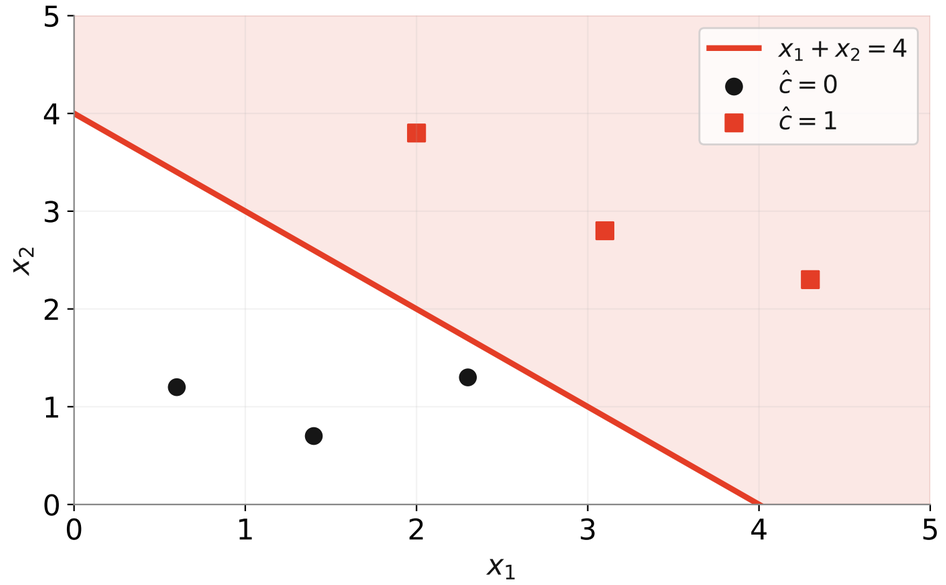
$$z = w_1 x_1 + w_2 x_2 + b$$

$$p = \sigma(z)$$

À $\tau = 0.5$, la frontière est $w_1 x_1 + w_2 x_2 + b = 0$.

La sigmoïde change l'échelle du score. Un seuil fixé donne toujours une frontière linéaire dans les caractéristiques initiales.

Illustration : $w_1 = w_2 = 1$, $b = -4$ ; unités arbitraires.




Classe 1 : $x_1 + x_2 \geq 4$. La région colorée représente les décisions prédites.

**Une courbe de probabilité non linéaire n'implique pas une frontière de décision non linéaire.**

# L’évaluation commence par les cas individuels

Huit cas de validation construits ; prédire 1 si $p \geq 0.5$. Ils sont distincts des six observations d’entraînement.

| Cas | p | Vrai c | Prédit | Type |
|---|---|---|---|---|
| A | .95 | 1 | 1 | TP |
| B | .85 | 1 | 1 | TP |
| C | .70 | 0 | 1 | FP |
| D | .60 | 1 | 1 | TP |
| E | .45 | 1 | 0 | FN |
| F | .30 | 0 | 0 | TN |
| G | .20 | 0 | 0 | TN |
| H | .10 | 0 | 0 | TN |

**Matrice de confusion** : colonnes = classes observées ; lignes = classes prédites.

| | Vrai 1 | Vrai 0 |
|---|---|---|
| **Prédit 1** | TP = 3 | FP = 1 |
| **Prédit 0** | FN = 1 | TN = 3 |

TP / TN : décisions positives / négatives correctes. FP : fausse alerte. FN : événement manqué.

$$n = TP + FP + FN + TN = 8$$

**Préciser la classe positive et l’orientation de la matrice de confusion.**

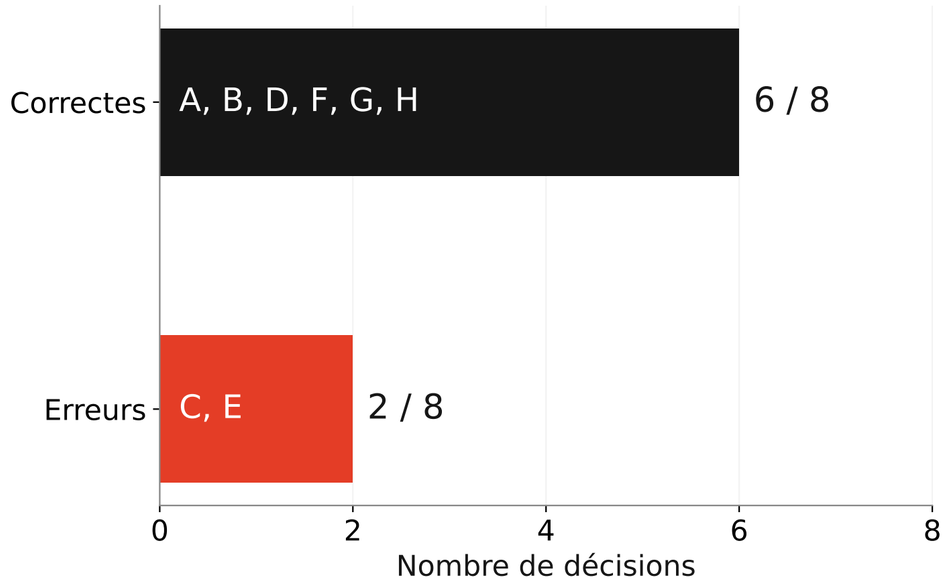
# Exactitude : quelle part des décisions est correcte ?

Compter toutes les décisions correctes, positives ou négatives, puis diviser par le nombre total de cas.

$$\text{Exactitude} = \frac{TP + TN}{TP + FP + FN + TN}$$

$$= \frac{3 + 3}{8} = 0.75$$

Cette mesure donne le même poids à chaque cas classé correctement ou incorrectement.




Nos huit cas : 6 décisions correctes et 2 erreurs. Ces deux erreurs ont des conséquences différentes.

**L’exactitude décrit la réussite globale, sans distinguer fausses alertes et événements manqués.**

# Précision et rappel utilisent des dénominateurs différents

**Précision :** lorsqu'une alerte est émise, à quelle fréquence est-elle correcte ?

$$\text{Precision} = \frac{TP}{TP+FP} = \frac{3}{4} = 0.75$$

Les positifs prédits sont A, B, C, D. Trois de ces quatre alertes sont correctes.

Les faux positifs réduisent la précision. C'est important si chaque alerte exige du temps ou des ressources.

**Rappel :** parmi les événements réellement survenus, combien ont été détectés ?

$$\text{Rappel} = \frac{TP}{TP+FN} = \frac{3}{4} = 0.75$$

Les positifs réels sont A, B, D, E. Trois de ces quatre événements ont été détectés.

Les faux négatifs réduisent le rappel, aussi appelé sensibilité ou taux de vrais positifs (TPR).

**La précision part des prédictions ; le rappel part des positifs observés.**

# F1 combine précision et rappel ; la spécificité évalue les négatifs

F1 est la moyenne harmonique de la précision P et du rappel R. Il est élevé si les deux le sont.

$$F_1 = \frac{2PR}{P+R} = \frac{2TP}{2TP+FP+FN}$$

$$F_1 = \frac{6}{6+1+1} = 0.75$$

F1 ignore les vrais négatifs. Il résume deux taux, sans remplacer une analyse des coûts propres à l'application.

La spécificité mesure la proportion de négatifs réels correctement laissés sans alerte.

$$\text{Specificite} = \frac{TN}{TN+FP} = \frac{3}{4}$$

$$\text{FPR} = \frac{FP}{FP+TN} = 1 - \text{Specificite}$$

Ici, spécificité = 0.75 et FPR = 0.25. Si un dénominateur est nul, préciser la convention utilisée.

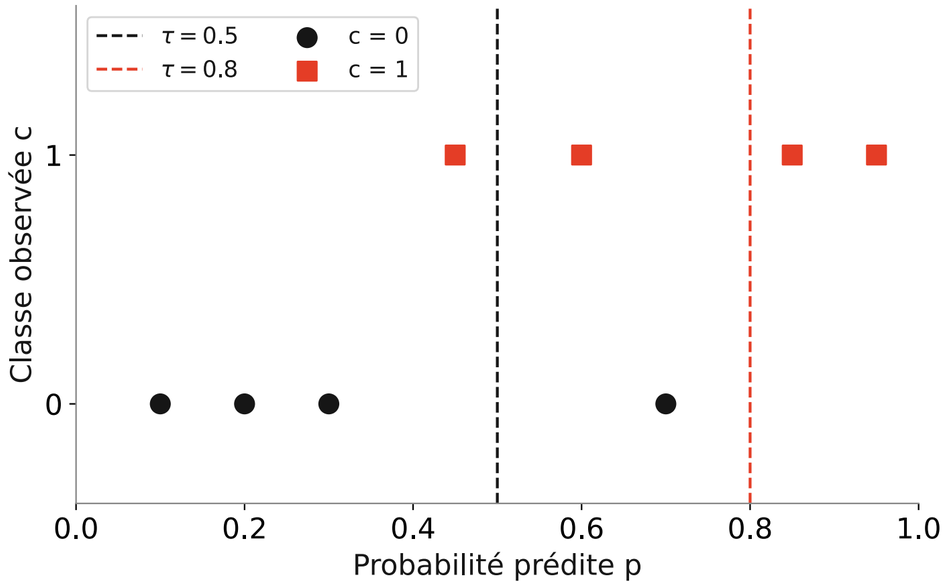
**Le rappel utilise les positifs réels ; la spécificité et le FPR utilisent les négatifs réels.**

# Changer le seuil modifie les erreurs

| τ | TP / FP / FN / TN | Précision | Rappel |
|---|---|---|---|
| **0.5** | 3 / 1 / 1 / 3 | 0.75 | 0.75 |
| **0.8** | 2 / 0 / 2 / 4 | 1.00 | 0.50 |

Les deux donnent une exactitude de 6/8. À 0.8, moins d’alertes sont émises et plus d’événements sont manqués.

À scores fixes, augmenter le seuil ne peut augmenter le rappel. La précision peut fluctuer.




Scores : .95, .85, .70, .60, .45, .30, .20, .10. Étiquettes : 1, 1, 0, 1, 1, 0, 0, 0.

**Choisir le seuil sur la validation selon l’usage ; le figer avant le test.**

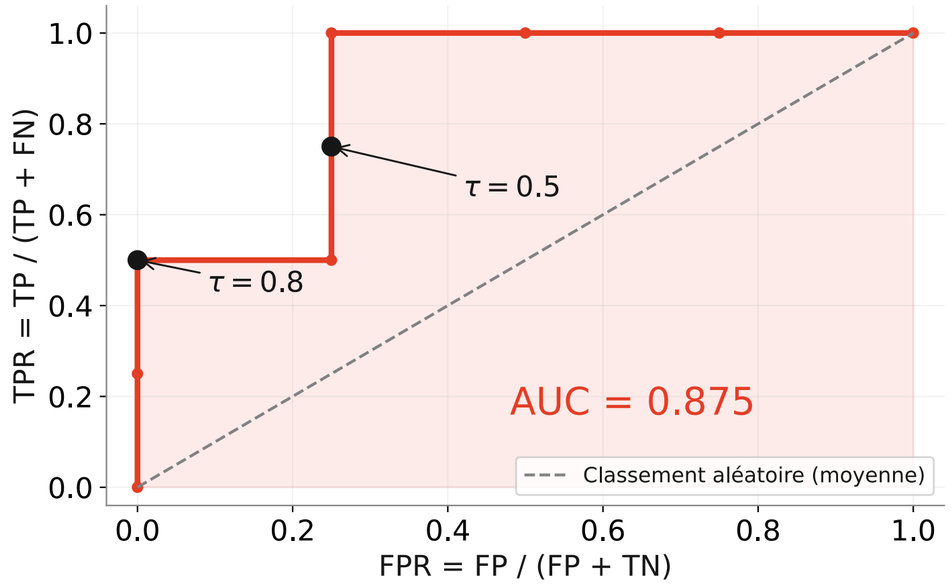
# ROC–AUC évalue le classement sur l'ensemble des seuils

Abaisser le seuil du dessus de tous les scores au dessous de tous les scores. À chaque étape, compter TP et FP et tracer un point.

$$\mathrm{TPR} = \frac{TP}{TP+FN}, \quad \mathrm{FPR} = \frac{FP}{FP+TN}$$

ROC place le TPR en ordonnée et le FPR en abscisse. Un bon classifieur s'approche du coin supérieur gauche.

Aire sous la courbe ROC : **AUC = 0.875** ici. Un classement aléatoire a une AUC moyenne de 0.5 ; un classement parfait, de 1.




Mêmes huit cas. À $\tau = 0.8$ : (FPR, TPR) = (0, 0.5). À $\tau = 0.5$ : (0.25, 0.75).

**L'AUC résume le classement ; elle ne choisit pas le seuil d'usage et ne mesure pas la calibration.**

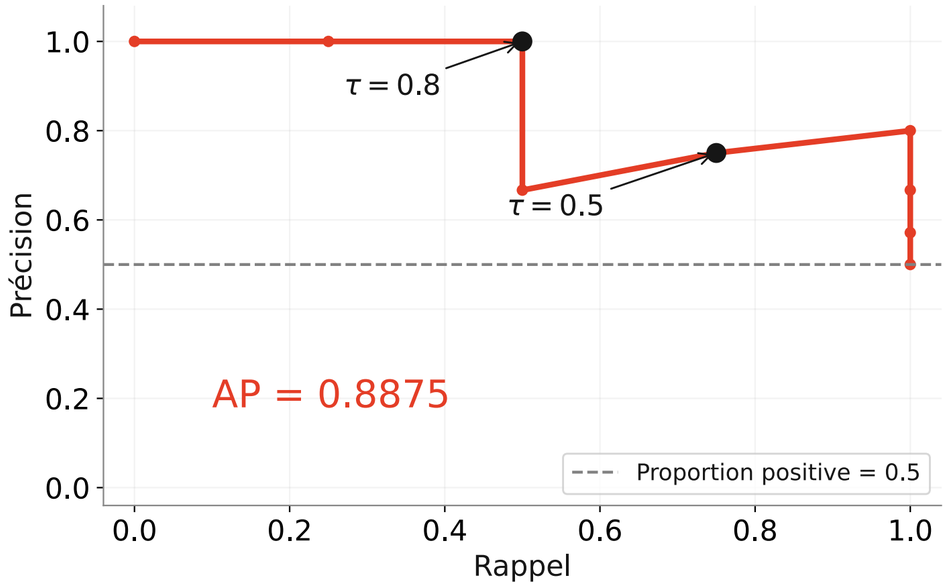
# La courbe PR se concentre sur les prédictions positives

Parcourir les mêmes seuils, avec la précision en ordonnée et le rappel en abscisse.

PR montre la fiabilité des alertes lorsqu'on détecte davantage de positifs. C'est particulièrement utile si les positifs sont rares.

$$\mathrm{AP} = \sum_k (R_k - R_{k-1}) P_k$$

La précision moyenne (AP) pondère la précision par le gain de rappel. Ici AP = 0.8875, selon une convention en marches, distincte de l'aire par trapèzes.




Mêmes cas ; proportion positive = 4/8 = 0.5. Points reliés dans l'ordre des seuils. Le point sans alerte utilise une précision de 1 pour le tracé.

**La précision dépend de la fréquence des classes : comparer PR sur des populations comparables.**

# Choisir la mesure selon la décision

Avec 10 positifs sur 1 000 cas, toujours prédire 0 donne 99 % d’exactitude, mais ne détecte aucun événement.

$$\text{Exactitude} = 0.99, \quad \text{Rappel} = 0$$

Rapporter fréquences, matrice de confusion et mesures complémentaires. Choisir le seuil sur la validation, puis le figer avant le test final.

| Question | Mesure utile |
|---|---|
| **Réussite des décisions ?** | Exactitude + référence |
| **Alertes fiables ?** | Précision |
| **Événements manqués ?** | Rappel |
| **Équilibre précision–rappel ?** | F1 |
| **Qualité du classement ?** | ROC–AUC / PR–AP |
| **Probabilités fiables ?** | Perte log + calibration |

**Aucune mesure unique ne décrit tous les aspects d’un classifieur.**

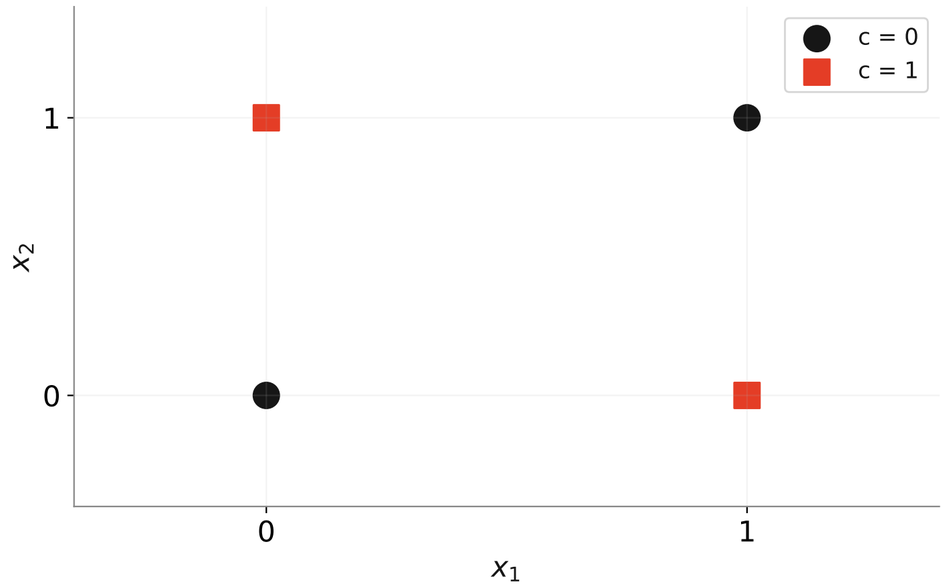
# Si une droite ne suffit pas, changer de représentation

Dans XOR, les positifs occupent des coins opposés. Aucune droite unique ne sépare les classes.

Introduire $\phi(x) = x_1 + x_2 - 2x_1x_2$. Sur les quatre entrées binaires, elle vaut 1 pour la classe 1 et 0 pour la classe 0.

$$p = \sigma(a\phi(x) + b)$$

Les réseaux apprennent des caractéristiques intermédiaires au lieu de toutes les définir à la main.




Avec ϕ, a = 2 et b = −1 classent les quatre entrées correctement au seuil 0.5.

**Des caractéristiques non linéaires permettent des frontières non linéaires dans les entrées initiales.**

# Questions sur la classification et l’apprentissage

**01** **Relier modèle et tâche**
Pourquoi la régression logistique classe-t-elle ? Expliquer le passage de x à p puis à une classe.

**02** **Retrouver le gradient**
Expliquer les deux facteurs de $(p-c)x$.

**03** **Évaluer un seuil**
Quels cas forment les dénominateurs de la précision et du rappel ?

**04** **Évaluer un classement**
Que résume ROC–AUC ? Choisit-elle le seuil ?

$$x \longrightarrow z \longrightarrow p \longrightarrow \hat{c}$$

$$\ell \longrightarrow \nabla J \longrightarrow \theta^{+}$$

La perte entraîne le modèle probabiliste. Le seuil transforme les probabilités en décisions de classe.

Pour $p = 0.7$, $\tau = 0.8$ et une classe observée $c = 1$ : quelle classe est prédite et quel type d’erreur se produit ?

**Définir → dériver → entraîner → évaluer → décider.**

# A1 · La dérivée de la moitié d’un carré

Une dérivée compare la variation de sortie à une très petite variation $h$ de l’entrée.

$$f(a) = a^2/2$$

$$f'(a) = \lim_{h \to 0} \frac{f(a+h) - f(a)}{h}$$

Pour une composition, multiplier la dérivée de la fonction extérieure par celle de la fonction intérieure.

$$\frac{(a+h)^2 - a^2}{2h}$$

$$= \frac{2ah + h^2}{2h} = a + \frac{h}{2}$$

$$\lim_{h \to 0} (a + h/2) = a$$

Appliquer avec $a = r_i$, puis $\partial r_i / \partial w = x_i$ et $\partial r_i / \partial b = 1$.

**Le facteur 1/2 compense le facteur 2 produit par la dérivation du carré.**

# A2 · Déduire la solution des moindres carrés

À partir de $\sum_i (wx_i + b - y_i) = 0$, avec les moyennes :

$$b = \bar{y} - w\bar{x}$$

Substituer dans $\sum_i x_i(wx_i + b - y_i) = 0$. En centrant :

$$w\sum_i (x_i - \bar{x})^2 = \sum_i (x_i - \bar{x})(y_i - \bar{y})$$

$$w_* = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$$

$$b_* = \bar{y} - w_*\bar{x}$$

Ici $\bar{x} = 2$, $\bar{y} = 21$. Numérateur : 20 ; dénominateur : 2. Donc $w_* = 10$, $b_* = 1$.

Si tous les x sont identiques, le dénominateur est nul : pente et biais ne sont pas identifiables séparément.

**La solution exacte précise quand les paramètres sont déterminés de manière unique.**

# A3 · Une origine probabiliste de la perte quadratique

Supposer $y_i = wx_i + b + \epsilon_i$, avec des erreurs gaussiennes indépendantes de moyenne nulle et variance commune fixée $\sigma^2 > 0$.

$$\epsilon_i \sim \mathcal{N}(0, \sigma^2)$$

La moyenne conditionnelle est la prédiction linéaire. Le bruit décrit la variation autour de cette moyenne.

$$-\log L = \frac{1}{2\sigma^2} \sum_i (y_i - wx_i - b)^2 + \text{const}$$

À variance fixée, facteurs et constantes ne changent pas les paramètres minimisant la perte.

| Modèle de cible | Log-vraisemblance négative |
|---|---|
| **Gaussien** | Erreur quadratique + constante |
| **Bernoulli** | Entropie croisée binaire |

**Une hypothèse de distribution permet de construire un objectif d'apprentissage.**

# A4 · Convexité et existence d’un optimum

Inclure le biais dans la matrice : $z = X\theta$. Le gradient et la hessienne de la BCE sont :

$$\nabla J = \frac{1}{n} X^\top (p - c)$$

$$\nabla^2 J = \frac{1}{n} X^\top D X$$

$$D_{ii} = p_i(1 - p_i) \geq 0$$

Pour tout vecteur v, $v^T H v$ est positif ou nul. La perte est convexe en les paramètres.

**01** **Nos données**

Les six étiquettes ne sont pas séparables par un seuil de distance ; l’optimum est fini ici.

**02** **Séparation parfaite**

Si un score sépare strictement les classes, augmenter son amplitude peut faire tendre la perte vers zéro sans minimum fini.

**03** **Régularisation**

Une pénalité peut limiter la taille des paramètres. Sa force se choisit sur la validation.

**La convexité décrit la forme de l’objectif ; l’existence d’un minimum fini est une autre question.**

# A5 · Calculer la perte de façon stable avec le score

Remplacer $p$ par $\sigma(z)$ dans la BCE :

$$\ell(z, c) = \log(1 + e^z) - cz$$

Pour z grand et positif, exp(z) peut dépasser les capacités numériques. Utiliser une forme équivalente :

$$\ell(z, c) = \max(z, 0) - cz + \log(1 + e^{-|z|})$$

L’exposant est toujours négatif ou nul. Les bibliothèques proposent softplus ou logaddexp stables.

L’objectif statistique est préservé ; son calcul numérique est amélioré.

**L’implémentation doit préserver les mathématiques même pour des scores extrêmes.**

# A6 · Réponses aux questions de classification

01 **1 · Classification**

Pour des classes binaires, apprendre $p = P(c = 1 \mid x)$, puis comparer p à un seuil pour choisir la classe.

02 **2 · Gradient**

$p - c$ dérive la perte selon le score ; x dérive le score selon w.

01 **3 · Dénominateurs**

La précision utilise les positifs prédits (TP+FP) ; le rappel, les positifs réels (TP+FN).

02 **4 · ROC–AUC**

L'AUC résume le classement des scores positifs et négatifs sur les seuils. Choisir le seuil d'usage sur la validation selon l'application.

$$0.7 < 0.8 \implies \hat{c} = 0, \quad c = 1 \implies FN$$

**Expliquer chaque opération par son rôle mathématique et sa place dans l'évaluation.**

# A7 · Notations et vocabulaire bilingue

| Symbole | Signification |
|---|---|
| $x_i$ | Entrée / caractéristique |
| $y_i,\ c_i$ | Cible numérique / classe binaire |
| $w, b, \theta$ | Poids, biais, paramètres |
| $z_i,\ p_i$ | Score linéaire, probabilité |
| $\ell_i,\ J$ | Perte individuelle, perte moyenne |
| $\eta,\ \tau$ | Pas d'apprentissage, seuil |

| English | Français |
|---|---|
| **Training** | Entraînement |
| **Inference** | Prédiction / inférence |
| **Likelihood** | Vraisemblance |
| **Overfitting** | Surapprentissage |
| **Accuracy** | Exactitude / taux de réussite |
| **Precision / recall** | Précision / rappel |

**Paramètres appris, réglages d'optimisation et seuils de décision ont des rôles différents.**

# A8 · Références : modèles et évaluation

**R1** · Andrew Ng · Stanford CS229 · Supervised learning

**R2** · Cornell CS4780 · Supervised learning setup

**R3** · scikit-learn · Common pitfalls and data leakage

**R4** · Google ML Crash Course · Classification thresholds

**R5** · scikit-learn · Model evaluation

**R6** · scikit-learn · Probability calibration

**Régression et classification partagent des principes de modélisation, d’optimisation et d’évaluation.**

# A9 · Sources historiques

**H1** · Legendre (1805) · On Least Squares · translated text

**H2** · Cox (1958) · The Regression Analysis of Binary Sequences

**H3** · Rumelhart, Hinton & Williams (1986) · Learning representations by back-propagating errors

**01** **Moindres carrés**
Combiner des mesures bruitées grâce à un objectif numérique explicite.

**02** **Régression binaire**
Relier la probabilité d’un événement aux variables explicatives.

**03** **Rétropropagation**
Utiliser la règle de chaîne pour calculer des dérivées à travers plusieurs couches.

**L’estimation des paramètres relie un modèle mathématique aux données observées.**

# A10 · Deux modèles partagent une structure d’apprentissage

| | Régression linéaire | Régression logistique |
|---|---|---|
| **Cible** | $y \in \mathbb{R}$ | $c \in \{0, 1\}$ |
| **Sortie** | $\hat{y} = wx + b$ | $p = \sigma(wx + b)$ |
| **Perte** | $(\hat{y} - y)^2/2$ | Entropie croisée |
| **Gradient du score** | $\hat{y} - y$ | $p - c$ |

**01 Définir**
Entrées, cible, modèle et objectif.

**02 Apprendre**
Calcul direct → dérivées → mise à jour.

**03 Évaluer**
Données réservées et mesures adaptées.

**04 Appliquer**
Fixer les paramètres ; calculer les prédictions.

**La cible modifie le modèle et la perte ; la logique d’apprentissage se conserve.**

# A11 · Déduire un seuil du coût des erreurs

Supposer $p$ fiable dans l'usage visé. Les erreurs coûtent $C_{\mathrm{FP}} > 0$ et $C_{\mathrm{FN}} > 0$ ; les décisions correctes coûtent zéro.

$$R(1) = C_{\mathrm{FP}}(1-p)$$

$$R(0) = C_{\mathrm{FN}}p$$

Choisir la décision de coût moyen attendu le plus faible.

$$R(1) \le R(0)$$

$$C_{\mathrm{FP}} \le (C_{\mathrm{FP}} + C_{\mathrm{FN}})p$$

$$p \ge \frac{C_{\mathrm{FP}}}{C_{\mathrm{FP}} + C_{\mathrm{FN}}}$$

Exemple : $C_{\mathrm{FP}} = 1$, $C_{\mathrm{FN}} = 4$ donne $\tau = 0.2$. Des événements manqués coûteux justifient plus d'alertes.

**Le seuil 0.5 correspond à des coûts d'erreur égaux sous ces hypothèses.**

# A12 · Vérifier les fréquences et la fiabilité des probabilités

Supposer 10 cas positifs sur 1 000. Toujours prédire 0 donne 99 % d’exactitude et un rappel nul.

$$\text{Exactitude} = 990/1000 = 0.99$$

$$\text{Rappel} = 0/10 = 0$$

Rapporter les proportions et comparer à une référence simple. Choisir les mesures selon les erreurs importantes.

**01 Calibration**

Parmi de nombreux cas notés autour de p = 0.7, environ 70 % devraient être positifs.

**02 Discrimination**

Le modèle doit classer les positifs au-dessus des négatifs.

**03 Déploiement**

Un changement de population ou de fréquence des classes peut modifier performance et calibration.

**La sigmoïde garantit une valeur entre 0 et 1 ; elle ne garantit pas la calibration.**

# A13 · Reconstruire ROC–AUC et la précision moyenne

Il y a 4 scores positifs et 4 scores négatifs : 16 paires. Les quatre positifs dépassent respectivement 4, 4, 3 et 3 négatifs.

$$\mathrm{AUC} = \frac{4+4+3+3}{16} = 0.875$$

En cas d'égalité, compter une demi-victoire. Géométriquement, l'aire ROC vaut aussi 0.25 × 0.5 + 0.75 × 1 = 0.875.

Le rappel augmente de 1/4 à chaque nouveau positif détecté. Lire la précision aux quatre seuils concernés :

| Seuil | Rappel | Précision |
|---|---|---|
| **.95** | .25 | 1 |
| **.85** | .50 | 1 |
| **.60** | .75 | .75 |
| **.45** | 1.00 | .80 |

$$\mathrm{AP} = \tfrac{1}{4}(1+1+0.75+0.80) = 0.8875$$

**Les deux résumés utilisent les mêmes scores et classes ; ils répondent à des questions différentes.**

# A14 · Étendre l’évaluation à plusieurs classes

Pour des classes exclusives, utiliser une matrice K × K. Pour la précision, le rappel et F1 de la classe k, considérer k comme positive et les autres comme négatives.

$$F_{1,\,\text{macro}} = \frac{1}{K}\sum_{k=1}^{K} F_{1,\,k}$$

Macro donne le même poids aux classes. La moyenne pondérée utilise leurs effectifs et peut être dominée par les classes fréquentes.

**01 Micro**

Additionner TP, FP et FN sur les classes, puis calculer la mesure.

**02 Cas à une seule étiquette**

Sur toutes les classes, micro-précision = micro-rappel = micro-F1 = exactitude si chaque cas reçoit une seule classe prédite.

**03 Multi-étiquette**

Plusieurs étiquettes peuvent être vraies. Préciser la moyenne par étiquette ou par exemple ; l’identité précédente ne vaut plus en général.

**Pour les résultats multiclasses, préciser les classes et la convention de moyenne.**

# A15 · Références : mesures de classification

**R7** · Google ML Crash Course · Accuracy, precision, recall and F1

**R8** · Google ML Crash Course · ROC and AUC

**R9** · scikit-learn · Precision–recall and average precision

**01** **Décisions fixées**

Matrice de confusion, précision, rappel et F1 dépendent du seuil choisi.

**02** **Classement des scores**

ROC et PR comparent les décisions obtenues sur une suite de seuils.

**03** **Qualité probabiliste**

La perte logarithmique et la calibration examinent les probabilités avant application d’un seuil.

**Garder les mêmes données, classe positive et convention de seuil pour comparer les mesures.**